Benchmark des modèles Ollama – Mission Givaudan

1. Objectif de la mission

La mission consiste à aider les commerciaux de Givaudan à identifier des clients potentiels en détectant les actualités et les informations pertinentes concernant différentes entreprises.

Le problème identifié est que les commerciaux passent parfois à côté d'informations importantes sur leurs prospects, notamment :

- Le lancement de nouveaux produits.
- L'ouverture de nouveaux marchés.
- Le développement de nouvelles gammes.
- Les investissements et acquisitions.
- Les innovations dans les secteurs de la cosmétique, de la beauté et de l'agroalimentaire.

Notre objectif dans ce document est donc de sélectionner les modèles Ollama capables d'analyser ces informations, de détecter des opportunités commerciales et de produire des fiches prospects pertinentes.

2. Modèles LLM à comparer

Les LLM sont utilisés pour comprendre les informations collectées, les analyser et générer des synthèses.

Modèle Ollama	Utilité pour la mission	Avantages	Limites
Qwen 2.5 1.5B	Extraction simple d'informations et résumé d'actualités.	Léger, rapide, déjà installé.	Raisonnement et analyse parfois limités.
Qwen 2.5 3B	Extraction structurée et qualification des prospects.	Bon compromis potentiel entre taille et capacités.	Plus gourmand que le 1.5B.
Qwen 2.5 7B	Analyse approfondie des actualités et détection de signaux commerciaux complexes.	Candidat plus robuste pour les tâches complexes.	Plus gourmand en mémoire.

Llama 3.2 3B	Analyse et synthèse des informations sur les entreprises.	Alternative légère à Qwen.	Qualité en français à évaluer.
Mistral 7B	Résumé et analyse de plusieurs informations commerciales.	Alternative généraliste intéressante.	Consommation de ressources plus élevée.

3. Modèles d'embeddings à comparer

Les modèles d'embeddings servent à transformer les informations en représentations numériques afin de retrouver les documents pertinents dans la base de connaissances.

Modèle Ollama	**Utilité pour la mission**	**Avantages**
Nomic Embed Text	Rechercher des informations pertinentes dans les actualités et documents d'entreprises.	Déjà installé et testé, 768 dimensions.
BGE-M3	Rechercher des informations dans des documents français et multilingues.	Intéressant pour des sources internationales.
mxbai-embed-large	Améliorer potentiellement la recherche sémantique.	Alternative à comparer avec Nomic.

4. Critères d'évaluation des modèles

Les modèles doivent être évalués selon les critères suivants :

Critère	**Objectif**
Compréhension du texte	Comprendre les actualités et les informations sur les entreprises.
Extraction d'informations	Collecter les informations sur les entreprises, leurs activités, leurs produits et leurs actualités.
Détection d'opportunités pertinentes	Repérer les événements pouvant représenter une opportunité commerciale pour Givaudan.

Qualification des prospects	Évaluer la pertinence potentielle d'une entreprise pour Givaudan.
Qualité des réponses	Produire des analyses précises, compréhensibles et pertinentes.
Fidélité aux sources	Éviter les informations inventées et justifier les résultats par des sources.
Rapidité	Mesurer le temps nécessaire pour analyser les informations.
Consommation des ressources	Évaluer la mémoire et les capacités matérielles nécessaires.

5. Exemples de tâches à réaliser

Pour comparer les modèles, nous pouvons leur soumettre les mêmes informations et vérifier leur capacité à :

1. Identifier les entreprises mentionnées dans un article.
2. Détecter le lancement d'une nouvelle gamme de parfums ou de cosmétiques.
3. Repérer une entreprise qui se développe sur un nouveau marché.
4. Identifier les signaux pouvant indiquer un besoin en arômes, parfums ou ingrédients de beauté.
5. Générer une fiche synthétique présentant un prospect et justifiant son intérêt potentiel.

6. Recommandation pour la mission

La configuration actuelle constitue un bon point de départ :

- Qwen 2.5 1.5B pour analyser les informations et générer des réponses.
- Nomic Embed Text pour rechercher les informations pertinentes dans les documents.
- ChromaDB pour stocker les informations et leurs embeddings.
- Python et FastAPI pour rendre les fonctionnalités accessibles à l'application de l'équipe Tech.

7. Conclusion

Pour répondre au besoin de Givaudan, les modèles Ollama doivent être capables de transformer des informations dispersées sur les entreprises en opportunités commerciales exploitables.

Le choix final devra privilégier les modèles qui permettent :

- D'identifier correctement les entreprises pertinentes.
- De détecter les actualités représentant des opportunités potentielles.
- De produire des fiches prospects fiables et sourcées.
- De fonctionner avec des ressources matérielles raisonnables.

Le meilleur modèle ne sera donc pas nécessairement le plus puissant, mais celui qui offre le meilleur compromis entre pertinence des prospects détectés, fiabilité des analyses, rapidité et consommation de ressources.

Remarque : cette comparaison constitue une présélection théorique. Les performances devront être mesurées sur le dataset fourni par le teck pour établir un véritable classement.