Veille par impact — point d'étape et demande d'avis

Givaudan AI Challenge, thématique 01 · brique Data · état au 12/11/2026, 15h30

> **Ce que j'attends de cette relecture.** Le pipeline fonctionne de bout en bout et le tri des actualités est fiable (≈ 92 %). Deux maillons restent faibles : le choix des entreprises concernées (37 % des entreprises attendues retrouvées) et la qualité des hypothèses rédigées par le LLM (43 % jugées plausibles). J'aimerais votre avis sur la méthode pour les améliorer, et sur la validité de notre protocole d'évaluation. Les questions précises sont en section 7.

1. Objectif

Transformer le flux d'actualités (réglementation, matières premières, tendances, mouvements d'entreprises) en **fiches d'opportunité commerciale** pour Givaudan (arômes et parfums) : pour chaque actualité pertinente, quels clients sont concernés, quelle hypothèse d'opportunité, quelle question leur poser. Contraintes : 100 % local (Ollama, pas d'API externe de LLM), français prioritaire, exposé par une API FastAPI documentée, fonctionnement hors ligne pour la démo.

2. Ce qui est construit

2.1 Le pipeline en 5 étapes

Étape	Ce qu'elle fait	Technique	LLM ?
1. Collecte	4 requêtes par mots-clés fixes (une par famille) sur 7 jours ; fusion, dédoublonnage.	API GDELT ; repli Google News RSS (GDELT bloqué sur le réseau du hackathon)	Non
2. Filtre	Garde les titres proches d'une des 4 familles et plus proches d'elles que de contre-exemples « hors périmètre ». Donne une famille et un score.	Embeddings bge-m3, similarité cosinus, seuil 0,50	Non
3. Analyse	3a : extrait des faits avec citation exacte du texte. 3b : déduit catégories de produits et pays touchés, dans un vocabulaire fermé (16 catégories, codes pays).	qwen3:8b, sortie JSON contrainte par schéma, 2 appels	Oui
4. Jointure	Croise catégories et pays avec une base de 45 groupes clients ; classe et garde les 5 premiers, chacun avec une raison et une source vérifiable.	Règles déterministes, base issue d'Open Food / Beauty Facts	Non
5. Hypothèses	Pour chaque entreprise retenue : hypothèse d'opportunité, question client, fenêtre d'action, niveau de confiance.	qwen3:8b, 1 appel, entreprises imposées par schéma	Oui

2.2 Garde-fous contre les inventions (sans LLM)

- Sorties LLM contraintes par JSON Schema (Pydantic) : catégories, pays et noms d'entreprises ne peuvent être choisis que dans des listes fermées. 100 % de JSON valides mesurés.
- Chaque fait doit citer le texte : citation rejetée si moins de 70 % de mots en commun avec l'article.
- Une hypothèse est rejetée si elle cite une entreprise hors liste ou ne s'appuie sur aucun fait numéroté.
- Les entreprises sont choisies par des règles, pas par le LLM : chaque rattachement est explicable.
- Confiance plafonnée à « moyen » quand seul le titre a pu être lu.

2.3 La jointure (étape 4) en détail

Chaque groupe de la base a un profil calculé sur un échantillon de ≈ 100 produits : nombre de produits par catégorie et pays de vente. Exemple : *Coty — 48 produits : soins visage 23, parfumerie fine 6 ; vendu en FR,*

NL, ES. Pour une actualité, le score d'un groupe est :

- **1 point par catégorie commune** entre l'analyse de l'actualité et le profil du groupe, + un bonus inférieur à 1 proportionnel à la part de ses produits dans cette catégorie ;
- **+1** s'il est vendu dans un pays cité (éliminé s'il ne l'est pas ; +0,5 si l'impact est mondial) ;
- **+2** si son nom ou une de ses marques apparaît dans le titre.

On garde les 5 meilleurs groupes sur 45 (paramètre MAX_COMPANIES_PER_NEWS) : coût LLM de l'étape 5 (≈ 40 à 75 s par actualité sur un portable) et lisibilité pour un commercial.

2.4 API et modes

GET /opportunities (collecte + pipeline complet ; paramètres : période, langues, max_articles collectés par requête, max_actualites analysées par le LLM, max_fiches renvoyées) · **POST /analyze** (une actualité fournie, sans collecte) · **GET /health**. Trois modes : live, démo (résultats figés, sans réseau ni LLM) et dummy (réponses fictives pour l'intégration). 33 tests unitaires, sans réseau ni LLM.

3. Comment on évalue

- **Jeu de référence** : 20 actualités réelles (13 pertinentes, 7 non pertinentes), annotées avec la pertinence, la famille, les entreprises attendues et l'opportunité attendue.
- **Annotation** : faite par un LLM indépendant du pipeline (Claude), alignée sur nos noms et familles, **sans validation par un expert métier Givaudan** (indisponible pendant le hackathon). Les scores mesurent l'accord avec un analyste sectoriel généraliste, pas avec la vérité terrain de Givaudan.
- **Mesure automatique** (script eval/run_eval.py) : on soumet les 20 actualités à l'API et on compare.
- **Notation des hypothèses** : chaque hypothèse produite est notée plausible / non plausible (même LLM indépendant).
- Limite : l'évaluation passe par POST /analyze, donc **la collecte n'est pas évaluée**.

4. Résultats (V2, avant corrections)

Critère	Étape testée	Résultat	Lecture
Précision / rappel du filtre	2	92,3 % / 92,3 %	12 VP, 1 FP, 1 FN, 6 VN
Famille exacte	2	91,7 % (11/12)	Bon
Sorties JSON valides	3, 5	100 % (38/38)	Le schéma contraint fonctionne
Entreprises justifiées (raison + source)	4	100 % (60/60)	Traçabilité assurée
Entreprises attendues retrouvées	3 + 4	**36,7 %**	**Point faible n° 1**
Hypothèses plausibles	5	**43 % (25/58)**	**Point faible n° 2**

5. Problèmes actuels

P1 — Le choix des entreprises (rappel 36,7 %)

- **Le score favorise les groupes présents partout.** Un point par catégorie commune : un distributeur (Carrefour, marques propres) présent faiblement dans beaucoup de catégories passe devant un spécialiste. Ferrero n'est retrouvé sur aucune des 7 actualités où il était attendu.
- **Plafond de 5 entreprises** : quand 6 sont attendues, on en rate mécaniquement.
- **L'étape 3 coche trop de catégories** (jusqu'à 5, dont des hors-sujet : parfumerie et soins pour une actualité sur la vanille alimentaire), ce qui dilue le classement.
- **Base d'entreprises fragile** : 45 groupes choisis à la main ; profils estimés sur ≈ 100 produits d'une base contributive et très française ; Reckitt et Shiseido sans catégorie exploitable ; profils parfois faussés par des

marques historiques (Procter & Gamble classé en snacks via Pringles).

P2 — La qualité des hypothèses (43 % plausibles)

Les garde-fous vérifient que les faits sont réels, pas que le raisonnement est juste. Défauts relevés :

Défaut	Exemple
Contresens sur la direction des prix	n03 vanille, n15 cacao : raisonnement sur une hausse quand les faits décrivent une baisse (ou l'inverse)
Hypothèses hors métier	n06 Nutri-Score : propositions sur l'emballage ou l'étiquetage, hors du métier d'un fabricant d'arômes
Prémisses absentes de l'article	n11 : hypothèse fondée sur une mesure que les faits ne mentionnent pas
Entreprises mal choisies	n12 : hypothèses pour les concurrents, pas pour L'Oréal, cité dans le titre
Fenêtres d'action incohérentes	n17 : délai sans rapport avec l'échéance du 31/07/2026 donnée dans les faits

P3 — Le filtre : erreurs à la frontière

Les 3 erreurs sont à moins de 0,03 du seuil : réglementation américaine (FDA) peu couverte par nos phrases de référence ; titre proche du thème sans annoncer de mesure (livre blanc Yuka) ; « les industriels s'inquiètent » qui fait basculer une taxe vers « mouvements d'entreprises ». Le seuil est gardé à 0,50 : le déplacer reviendrait à l'ajuster sur une ou deux actualités.

P4 — La collecte

GDELT est resté bloqué (limite de débit sur l'IP partagée du hackathon). Google News RSS prend le relais, mais ses liens sont des redirections : on n'analyse alors que le titre, et la confiance est plafonnée.

P5 — L'évaluation elle-même

- 20 actualités : un écart de 1 actualité vaut 5 à 8 points de pourcentage.
- Vérité terrain et notation produites par un LLM, sans expert métier.
- **On corrige en regardant les erreurs du jeu, puis on remesure sur le même jeu** : les scores après correction sont optimistes. Il n'existe pas encore de jeu de test séparé.

6. Corrections tentées

Correction	Problème visé	Effet mesuré	Décision
a. Pays ignoré pour les matières premières	« Côte d'Ivoire » (pays producteur de cacao) lu comme un marché : 0 entreprise	n10 : 0 → 5 fiches, 0/5 → 2/5 attendues	Gardée
b. Hypothèse garantie pour l'entreprise citée dans le titre	L'Oréal ignoré par l'étape 5 (n12)	Second appel ciblé ; L'Oréal a sa fiche	Gardée
c. Score = part des produits dans les catégories ; 3 catégories max	Spécialistes battus par les généralistes	Rappel global 36,7 % → 32,7 % ; Nestlé disparaît de 11 actualités ; sensibilité au choix du LLM	Écartée

La correction c pénalise par construction les groupes diversifiés (Nestlé : 7 catégories à 17-26 % chacune, il n'en domine aucune). Aucun score intermédiaire n'a été testé sur le jeu d'évaluation pour éviter le sur-ajustement. Prévu ensuite : 4 règles dans le prompt de l'étape 5 (goût, odeur ou formulation uniquement ; sens de variation repris des faits ; aucune prémisse absente ; fenêtre calculée à partir des dates).

7. Questions pour vous

Sujet	Question
Score de la jointure	Comment mesurer qu'un groupe est concerné par une catégorie sans pénaliser ni les spécialistes ni les généralistes ? Pondération par chiffre d'affaires (quelle source ouverte ?), similarité sémantique actualité ↔ portefeuille de marques, ou apprentissage d'un classement ?
Nombre d'entreprises	Top 5 fixe, seuil de score, ou nombre variable selon l'actualité ?
Qualité des hypothèses	Avec un modèle local de 8B, faut-il plutôt durcir le prompt, ajouter un second passage de vérification (LLM juge), décomposer la tâche, ou accepter un modèle plus gros ?
Contrôle du raisonnement	Des contrôles déterministes sont-ils possibles pour le sens des variations (hausse / baisse) et la cohérence des dates, ou faut-il un juge ?
Protocole d'évaluation	Quelle taille minimale de jeu, et comment séparer jeu de mise au point et jeu de test avec si peu d'exemples ? Une annotation par LLM indépendant est-elle défendable faute d'expert, et comment la présenter ?
Filtre	Rester sur la similarité avec des phrases de référence, ou passer à un petit classifieur supervisé dès qu'on a quelques centaines d'exemples annotés ?
Base d'entreprises	Open Food / Beauty Facts est-il une base raisonnable pour profiler des clients, ou connaissez-vous une meilleure source ouverte (Wikidata, rapports annuels) ?

Code : dossier *veille/* (pipeline), *eval/* (évaluation), *tests/*. Détails et chiffres : README, sections 3, 7 et 8. Résultats bruts : eval/results_v2_avant.json, eval/results_v2_apres.json, eval/hypotheses_to_rate_v2_avant.csv.